

Informe Final

Laboratorio 11 - Introducción a la Visualización de los Datos

Nombre del estudiante:	Deiner Barrios
Curso:	Programación para la Analítica de Datos
Laboratorio:	Lab 11 - Introducción a la visualización de los datos
Herramienta utilizada:	Python (Google Colab)
Fecha:	22/09/2026

1. Ejercicio de práctica 1 - Detección de valores atípicos (Bike Sales)

Se analizó el conjunto de datos Bike_Sales_Outlier_Lab.xlsx utilizando Python (pandas y matplotlib) en Google Colab, con el fin de identificar valores atípicos en la cantidad de pedidos (Order_Quantity) durante el mes de diciembre de 2021.

1.1 Carga y exploración del conjunto de datos

Se importaron las librerías necesarias y se cargó el archivo de Excel, verificando el nombre de las columnas disponibles.

```
[0]: import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

data = pd.read_excel("Bike_Sales_Outlier_Lab.xlsx")
data.columns = data.columns.str.strip()
print(data.columns.tolist())

['Sales_Order #', 'Date', 'Day', 'Month', 'Year', 'Customer_Age', 'Age_Group', 'Customer_Gender', 'Country', 'State', 'Product_Category', 'Sub_Category', 'Order_Quantity']

[0]: ventas_por_dia = data.groupby('Date')['Order_Quantity'].sum().sort_values(ascending=False)
print(ventas_por_dia.head(10))

Date
2021-12-19    43
2021-12-18    19
2021-12-20    13
2021-12-12    13
2021-12-08    11
2021-12-05    10
2021-12-22    10
2021-12-16     8
2021-12-11     8
2021-12-07     6
Name: Order_Quantity, dtype: int64
```

1.2 Agrupación por fecha (equivalente a la tabla dinámica)


Se agruparon los datos por fecha, sumando la cantidad de pedidos (Order_Quantity) de cada día.

¿En qué fecha de diciembre se registró la mayor cantidad de ventas? El 19 de diciembre de 2021.

¿Cuál fue la cantidad de ventas? 43 unidades, muy por encima del resto de los días (el segundo valor más alto es 19, del 18 de diciembre).

1.3 Gráfico de dispersión por fecha

Se construyó un gráfico de dispersión de la suma diaria de Order_Quantity para visualizar el comportamiento de las ventas a lo largo del mes.



Interpretación: el gráfico permite identificar con claridad que el punto correspondiente al 19 de diciembre se aleja significativamente del resto de los datos, confirmando visualmente la presencia de un valor atípico.

1.4 Identificación de la orden responsable del valor atípico

Utilizando funciones equivalentes a GRANDE y PEQUEÑO de Excel (nlargest y nsmallest en pandas), se identificaron los 5 días con mayor cantidad de ventas y los 6 días con menor cantidad.


Después, se revisaron en detalle todas las órdenes registradas el 19 de diciembre para determinar cuál de ellas es la principal responsable del valor atípico.



¿Qué número de pedido es el más responsable del valor atípico? El pedido Sales_Order # 261765, con 11 unidades y \$25.520 en ingresos - muy por encima de las demás órdenes de ese mismo día, que oscilan entre 2 y 4 unidades.

1.5 Relación entre cantidad de órdenes e ingresos

Como análisis complementario, se graficó la relación entre Order_Quantity y Revenue para todo el conjunto de datos.



Interpretación: en general, a mayor cantidad de órdenes el ingreso tiende a aumentar, aunque existe variabilidad - algunas órdenes pequeñas generan ingresos altos, probablemente por productos de mayor valor. El punto en la esquina superior derecha, con una cantidad de órdenes moderada pero un ingreso muy superior al resto, corresponde al valor atípico identificado en la Figura 3 y confirma que se trata de una venta inusualmente alta.

1.6 Preguntas de reflexión

Factores que podrían determinar si un valor atípico debe o no considerarse en el análisis final de un conjunto de datos:


- Si el valor refleja un error de captura o registro de datos, o si corresponde a un evento real (por ejemplo, una venta corporativa o de gran volumen).
- Si el valor distorsiona significativamente medidas estadísticas como el promedio o la tendencia general del conjunto de datos.

- El tamaño de la muestra: en conjuntos de datos grandes el impacto de un outlier es menor; en muestras pequeñas (como este dataset de 88 registros), su efecto es mucho más notorio.
- Si existe evidencia o contexto de negocio que explique el valor como legítimo y no como un error.
- El objetivo del análisis: para modelos de pronóstico puede convenir eliminarlo o normalizarlo, mientras que para detectar eventos especiales o fraude, el outlier puede ser precisamente el dato de interés.

2. Ejercicio de práctica 2 - Visualización de escenarios reales


A continuación se desarrolla el código y la visualización correspondiente a cada uno de los cuatro escenarios propuestos, con su respectiva interpretación.

2.1 Comparación de calificaciones de estudiantes en diferentes asignaturas




Interpretación: los estudiantes obtienen mejores resultados en Arte y Ciencias, mientras que Historia presenta el promedio más bajo del grupo de asignaturas evaluadas.

2.2 Comparación del tiempo de carga de diferentes páginas web




Interpretación: el Sitio C es el más rápido en cargar (0.9 segundos), mientras que el Sitio D es el más lento (3.0 segundos), lo que lo convierte en el principal candidato para optimización.

2.3 Relación entre horas de estudio y rendimiento académico



Interpretación: se observa una correlación positiva clara entre las horas de estudio y el rendimiento académico - a medida que aumentan las horas dedicadas al estudio, las calificaciones también aumentan de forma consistente.

2.4 Distribución de salarios en tres departamentos distintos



Interpretación: el departamento de IT presenta la mediana salarial más alta y mayor dispersión de valores, mientras que Recursos Humanos muestra la menor variabilidad salarial. Administración se ubica en un punto intermedio entre ambos departamentos.

3. Conclusión general

El desarrollo de este laboratorio permitió aplicar distintas técnicas de visualización de datos en Python (gráficos de dispersión, de barras, horizontales y de cajas) para identificar valores atípicos y comparar comportamientos entre variables.

Link Google Colab Código:

https://colab.research.google.com/drive/1N4vC_CLscZQiFYP1NbyBoSmv9pKilwSD?usp=sharing

Repositorio de GitHub: <https://github.com/deinerb93-create/-lab11-visualizacion-datos>